

דוח מטלה 1

החלטות שנלקחו:

- השתמשנו בדף המרכז של ויקיפדיה שמכיל את כל הסרטים בשביל למצוא את כל הסרטים באות שלנו ככה במידה ונבחר לקחת רק חלק מהסרטים המוצאים לנו ניתן עדיפות לסרטים שיש לה עמוד בוויקיפדיה. בשביל יצרנו דאטה פריים ראשוני שמכיל את כל הסרטונים מהעמוד המרכז שלנו והשוונו עם הטבלאות מimdb.
- שימוש תחילה בטבלאות של imdb. המקור נתונים שהרגיש לנו הכי נוח להתחיל ולבנות סביבו את בסיס הנתונים.
- קודם להתחיל עם הגבלה של הרצת 20 סרטים לתוך הדאטה ככה היה אפשר לעבוד בנוחות בלי ריצות ארוכות.
- כאשר התחלנו לסרוק מויקיפדיה גילנו שיש סרטים שאם מחפשים את השם שלהם זה לא פונה לדף הסרט אלא למשהו אחר שעל שמו הסרט (עיר, שנה, אירוע) לכן חייב להוסיף בסוף הכתובת (film)_.
- לכן הוחלט שקודם כלל לתת לפייתון לרוץ בלולאה שבכל סרט היא בודקת דבר ראשון אם היא מוצאת סרט שמופיע עם (film)_. ולא אז לחפש את שם הסרט כרגיל.
- גם לתקציב וגם להכנסות לעשות רגאקס שחותך את הפיסק וגם מוריד את המילה מיליון אם צריך
- עקב הגבלת 1000 הרצות ביום של OMDB החלטנו לתת קודם כל לויקיפדיה לתת לנו התקצרים ואז להשלים כמה שאפשר עם OMDB שזה נשמר ממש לסוף אחרי שכל הקוד מוכן על מנת לחסוך בהרצות.
- החלטנו לשמור לבסוף אחרי שכל הפרמטרים מוכנים את המרת הפרמטרים לטיפוסים הרצויים.

תיאור השדות:

שדה	טיפוס	תיאור	מקור	ערכים חסרים
tconst	str	מספר מזהה של הסרט בimdb.	IMDB (title.basics)	0
primaryTitle	str	שם הסרט.	IMDB (title.basics)/ Wikipedia	0
startYear	numpy.int32	שנת יציאת הסרט.	IMDB (title.basics)	0
runtimeMinutes	numpy.int32	זמן הסרט בדקות.	IMDB (title.basics)	0
genres	list	הז'אנרים התואמים לסרט	IMDB (title.basics)	530 (5.5%)
averageRating	numpy.float64	ממוצע הדירוגים בIMDB.	IMDB (title.ratings)	2725 (28.65%)
numVotes	numpy.int64	כמות המצביעים לדירוג הסרט.	IMDB (title.ratings)	2725 (28.65%)
lead_actors_ids	list	רשימת 5 השחקנים המובילים.	IMDB (title.principals)	1461 (15.36%)
language	str	השפה הראשית בסרט.	Wikipedia	6903 (72.59%)
Country	str	מדינת המקור של הסרט.	Wikipedia	7188 (75.58%)
Budget	numpy.float64	תקציב הסרט במיליוני דולרים.	Wikipedia	9023 (94.88%)
Box_Office	numpy.float64	הכנסות הסרט במיליוני דולרים.	Wikipedia	8870 (93.27%)
Plot	str	תקציר הסרט.	Wikipedia עם השלמה של OMDb.	5430

(57.01%)				
----------	--	--	--	--

בס"ד

*סה"כ נאספו 9510 סרטים

סיבות ערכים חסרים:

- **tconst, primaryTitle, startYear, runtimeMinutes** – פה יש לנו פרמטרים מהטבלה המקורית של imdb לכן לא היה ערכים חסרים בכלל.
- **genres** – יש סרטים שimdb לא הגדיר להם ז'אנר בכלל.
- **lead_actors_ids** – לרוב מרבית הערכים החסרים פה הם סרטים דוקומנטריים שאין להם שחקנים.
- **averageRating ו numVotes** - היה אותו מספר מדויק של ערכים מספרים, נובע מסרטים שimdb לא נתנו את האופציה בכלל לדרג אותו למשתמשים ככה שאין לו דירוג כלל.

הנתונים הנ"ל הבואו מויקיפדיה, לכן פה כבר נוצרה בעיה כי רק כ-15% מסרטים בסט שלי הופיע בויקיפדיה.

- **Budget, Box_Office, Language, Country** – פרמטרים שהיו תלויים בהופעת הסרטים בויקיפדיה ובנוסף גם לא בכל הדפים הופיע כל אחד מהפרמטרים במיוחד תקציב והכנסות שהיגיע לאחוזים מאוד גבוהים של ערכים נמוכים.
- **Plot** – פה היה לי אופציה לנסות להוסיף נתונים באמצעות `apikey` מ `omdb`. הוגבלתי ל-1000 ביום לכן עקב באגים ודריסה של המערכת הצלחנו רק יומיים לסוף להוסיף את כמות הסרטים הזאת. ככל הנראה שאם ההגשה היית מתארכת בעוד מספר ימים אחוזי הערכים היה קטן משמעותית.

חשוב מאוד לציין שבחרנו להוסיף כמה שיותר נתונים לכן עקב כך הסרטים השופעים במידע תפסו משקל נמוך יותר אך נתתי לסרטים המופיעים בויקיפדיה קדימות בתחילת הדאטה.

תודה רבה!